

Západočeská univerzita v Plzni
Fakulta aplikovaných věd
Katedra informatiky

DIPLOMOVÁ PRÁCE



PLZEŇ, 2024

Milan Horínek

PROHLÁŠENÍ

Předkládám tímto k posouzení a obhajobě bakalářskou práci zpracovanou na závěr studia na Fakultě aplikovaných věd Západočeské univerzity v Plzni.

Prohlašuji, že jsem bakalářskou práci vypracoval samostatně a výhradně s použitím odborné literatury a pramenů, jejichž úplný seznam je její součástí.

V Plzni dne 6. listopadu 2023

.....

Milan Horínek

PODĚKOVÁNÍ

ANOTACE

Autor se zabývá problematikou přistávání raket a tím, že většina prací na toto téma používá model RL. Autor se však rozhodl použít pro řízení dopředný výpočet přistávací trajektorie. Autor stručně popisuje dvě metody řízení, které byly testovány - zpětnou vazbu a numerické řešení ze simulace. Bylo zjištěno, že druhá metoda je přesnější, ale první je vhodnější pro model 3DoF. Autor navrhuje možná rozšíření práce, například přidání rušivých vlivů, jako je vítr, a zvýšení robustnosti a přesnosti řídicího systému.

Klíčová slova: raketa, přistání, VTVL, pinpoint landing

ABSTRACT

The author discusses the problem of rocket landing, and how most works on the topic use the RL model. However, the author decided to use forward calculation of the landing trajectory for control. The author briefly describes two control methods that were tested – feedback and numerical solution from the simulation. The latter was found to be more accurate, but the former was more suitable for the 3DoF model. The author suggests possible extensions for the work, such as adding disturbances such as wind, and increasing the robustness and accuracy of the control system.

Key words: raketa, přistání, VTVL, pinpoint landing

ZADÁNÍ

1. Prozkoumejte dostupné práce na téma řízení polohy rakety a přistávacího manévru
2. Navrhněte zjednodušený model rakety včetně potřebných příslušných technických prostředků (aktuátorů, senzorů, atd.)
3. Navrhněte algoritmus řízení letu rakety včetně potřebných letových módů
4. Implementujte model a regulační smyčku ve vybraném simulačním prostředí
5. Zhodnoťte získané výsledky

ASSIGNMENT

1. Explore available papers on rocket attitude control and landing maneuver
2. Create a simplified model of rocket including the necessary technical means (actuators, sensors, etc.)
3. Design a rocket flight control algorithm including the necessary flight modes
4. Implement the model and control loop in the chosen simulation environment
5. Evaluate the obtained results

Obsah

1	Úvod	6
2	Provedená práce v problematice	7
2.1	Předchozí automatizovaná řešení	7
2.1.1	Programatická řešení	7
2.2	Vydané publikace	8
2.2.1	Srovnání výsledků	9
2.3	Modely	9
2.3.1	Srovnání modelů	9

Slovník pojmů

LLM Velký jazykový model (LLM - large language model) je typ modelu strojového učení, který je navržen tak, aby rozuměl a generoval text v přirozeném jazyce. Tyto modely jsou trénovány na obrovských datasetech a jsou schopny provádět různé úkoly, jako je textová klasifikace, generování textu, strojový překlad a další. 7

testové pachy Unit Test Smells jsou špatné návyky nebo postupy, které se mohou objevit při psaní jednotkových testů. Tyto "smelly" často vedou k neefektivním nebo nespolehlivým testům a mohou ztížit údržbu testovacího kódu. Příklady zahrnují Duplicated Asserts, Empty Tests a General Fixture. 7

1 Úvod

2 Provedená práce v problematice

2.1 Předchozí automatizovaná řešení

Jazykové modely nebyli prvními pokusy o automatizované generování jednotkových testů. Ještě před nimi existovala spousta metod zahrnující příklady jako *fuzzing*, *generování náhodných testů řízených zpětnou vazbou*, *dynamické symbolické exekuce*, *vyhledávací a evoluční techniky*, *parametrické testování*. Zároveň také již na počátku století byli pokusy o vytvoření vlastní neuronové sítě sloužící právě čistě k úkolu testování softwaru. V této sekci je ukázka několika z nich.

2.1.1 Programatická řešení

Jedna z používaných programatických automatizovaných metod pro tvorbu jednotkových testů je tzv. *fuzzing*. V rámci těchto testů musí uživatel stále definovat jeho kódovou strukturu, resp. akce, které test bude provádět a jaký výstup očekávat. Automaticky generovaný je pouze vstup tohoto testu. Výhodou zde tedy je, že uživatel nemusí vytvářet maketu vstupních dat testu, která se zde vytvoří automatizovaně. Zůstává zde však problematika, že pro uživatele není kód *black-box*, ale celou jeho strukturu včetně požadovaného výstupu musí sám definovat.

Pouze vstupy dokáže také generovat metoda *dynamické symbolické exekuce*, která postupně analyzuje chování větvení programu. Začíná bez předchozích znalostí a používá řešič omezení k nalezení vstupů, které prozkoumají nové cesty exekuce. Jakmile jsou testy spuštěny s těmito vstupy, nástroj sleduje cestu, kterou program bere, a aktualizuje svou znalostní bázi (q) s novými podmínkami cesty (p). Tento iterativní proces pokračuje, zpřesňuje sadu známých chování a snaží se maximalizovat pokrytí kódu. Nástroje běžně zvládají různé datové typy a respektují pravidla viditelnosti, používají mock objekty a parametrizované makety k simulaci různých chování a vstupů, čímž zlepšuje proces generování testů, aby odhalily potenciální chyby a zajistily komplexní pokrytí testů. [1] Tato metoda je implementována například v nástroji *IntelliTest* v rámci IDE *Visual Studio*. Je používána v kombinaci s *parametrickými testy*, také označovanými jako PUT. Ty na rozdíl od tradičních jednotkových testů, které jsou obvykle uzavřené metody, mohou přijímat libovolnou sadu parametrů. Nástroje se pak snaží automaticky generovat (minimální) sadu vstupů, které plně pokryjí kód dosažitelný z testu. Nástroje jako např. *IntelliTest* automaticky generují vstupy pro put, které pokrývají mnoho výkonnostních cest testovaného kódu. Každý vstup, který pokrývá jinou výkonnostní cestu, je „serializován“ jako jednotkový test. Parametrické testy mohou být také obecné metody, v tom případě musí uživatel specifikovat typy použité k instanci metody. Testy také mohou obsahovat atributy pro očekávané a neočekávané vyjímky. Neočekávané vyjímky vedou k selhání testu. put tedy do velké míry redukuje potřebu uživatelského vstupu pro tvorbu jednotkových testů. [2] [3]

Další metodou je *náhodné generování testů řízené zpětnou vazbou*, která je vylepšením pro generování náhodných testů tím, že zahrnuje zpětnou vazbu získanou z provádění testovacích

vstupů v průběhu jejich vytváření. Tato technika postupně buduje vstupy tím, že náhodně vybírá metodu volání a hledá argumenty mezi dříve vytvořenými vstupy. Jakmile je vstup sestaven, je proveden a ověřen proti sadě kontraktů a filtrů. Výsledek provedení určuje, zda je vstup redundantní, nelegální, porušující kontrakt nebo užitečný pro generování dalších vstupů. Technika vytváří sadu testů, které se skládají z jednotkových testů pro testované třídy. Úspěšné testy mohou být použity k zajištění, že kontrakty kódu jsou zachovány napříč změnami programu; selhávající testy (porušující jeden nebo více kontraktů) ukazují na potenciální chyby, které by měly být opraveny. Tato metoda dokáže vytvořit nejen vstup pro test, ale i tělo (kód) testu. Ovšem pro uživatele je stále vhodné znát strukturu kódu. [4]

2.2 Vydané publikace

Jeden z poměrně nedávno vydaných článků (září 2023) nazvaný „An Empirical Evaluation of Using Large Language Models for Automated Unit Test Generation“ [5] se zabývá využitím velkých jazykových modelů (LLM) pro automatizované generování jednotkových testů v jazyce JavaScript. Implementovali nástroj s názvem **TESTPILOT**, který využívá LLM *gpt3.5-turbo*, *code-cushman-002* od společnosti OpenAI a také model StarCoder, který vznikl jako komunitní projekt [6]. Vstupní sada pro LLM obsahovala signatury funkcí, komentáře k dokumentaci a příklady použití. Nástroj byl vyhodnocen na 25 balíčcích npm obsahujících celkem 1684 funkcí API. Vygenerované testy dosáhly pomocí *gpt3.5-turbo* mediánu pokrytí příkazů 70,2% a pokrytí větví 52,8%, čímž překonaly nejmodernější techniku generování testů v jazyce JavaScript zaměřenou na zpětnou vazbu, Nessie.

Zmíněný model *StarCoder* byl představen v článku „StarCoder: may the source be with you!“ [6] z května 2023. Vytvořeny byly konkrétně 2 verze, *StarCoder* a *StarCoderBase*, s 15,5 miliardami parametrů a délkou kontextu 8K. Tyto modely jsou natrénovány na datové sadě nazvané *The Stack*, která obsahuje 1 bilion tokenů z permissivně licencovaných repozitářů GitHub. *StarCoderBase* je vícejazyčný model, který překonává ostatní modely open-source LLM modely, zatímco *StarCoder* je vyladěná verze speciálně pro Python, která se vyrovná nebo překoná stávající modely zaměřené čistě na Python. Článek poskytuje komplexní hodnocení, které ukazuje, že tyto modely jsou vysoce efektivní v různých úlohách souvisejících s kódem.

Článek „Exploring the Effectiveness of Large Language Models in Generating Unit Tests“ [7] z dubna 2023 hodnotí výkonnost tří LLM - *Codex*, *CodeGen* a *GPT-3.5* - při generování jednotkových testů pro třídy jazyka Java. Studie používá jako vstupní sady dva benchmarky, *HumanEval* a *Evosuite SF110*. Klíčová zjištění ukazují, že *Codex* dosáhl více než 80% pokrytí v datové sadě *HumanEval*, ale žádný z modelů nedosáhl více než 2% pokrytí v benchmarku *SF110*. Kromě toho se ve vygenerovaných testech často objevovaly tzv. testové pachy, jako jsou *duplicitní tvrzení* a *prázdné testy* [8].

2.2.1 Srovnání výsledků

2.3 Modely

Jedním z často používaných modelů v předchozích pracích je *StarCoder* a *StarCoderBase*, diskutovaný již v sekci 2. *Base* verze je schopna generovat kód pro více jak 80 programovacích jazyků. Model je navržen pro širokou škálu aplikací obsahující *generování*, *modifikaci*, *doplňování* a *vysvětlování* kódu. Jeho distribuce je volná a licence **CodeML OpenRAIL-M 0.1** [9] umožňuje ho využívat pro množství aplikací včetně komerčních nebo edukačních. Jeho uživatel však má povinnost uvádět, že výsledný kód byl vygenerován modelem. Licence má své restriktce z obavy tvůrců, protože by model mohl někoho při nepsprávném použití ohrozit. Tyto restriktce se aplikují na všechny derivace projektů pod touto licencí. Zároveň není kompatibilní s Open-Source licencí právě kvůli těmto restrikcím.

Nedávno vydaným modelem je *Code Llama* od společnosti Meta. Jedná se o evoluci jejich jazykového modelu *Llama* specializovaný však čistě na úlohy kódování. Je postaven na platformě *Llama 2* a existuje ve třech variantách: *základní Code Llama*, *Code Llama - Python* a *Code Llama - Instruct*. Model podporuje více programovacích jazyků, včetně jazyků jako Python, C++, Java, PHP, Typescript, C nebo Bash. Je určen pro úlohy, jako je generování kódu, doplňování kódu a ladění. *Code Llama* je zdarma pro výzkumné i komerční použití a je uvolněn pod licencí MIT. Uživatelé však musí dodržovat zásady přijatelného použití, ve kterých je uvedeno, že model nelze použít k vytvoření služby, která by konkurovala vlastním službám společnosti Meta.

Velmi populárním nástrojem pro generování kódu za pomoci LLM je GitHub Copilot, který je postaven na modelu *codex* od OpenAI. Původní model však byl přestal být zákazníkům nabízen a namísto něj OpenAI doporučuje ke generování kódu využívat chat verze modelů GPT-3.5 a GPT-4. Na architektuře GPT-4 je také postavený nástupce služby Copilot, Copilot X. Zmíněné modely chat GPT-3.5 a GPT-4 jsou primárně určeny pro generování textu formou chatu. Zvládají však zároveň i dobře generovat kód a jsou vhodné i úlohu generování jednotkových testů. Narozdíl od předchozích modelů však nejsou volně distribuovány a jsou poskytovány pouze jako služba společností OpenAI skrze API nebo je lze hostovat v rámci služby Azure společnosti Microsoft, která zajišťuje větší integritu dat. Jedná se tedy o uzavřený model a jeho uživatelé musí souhlasit s jeho podmínkami použití.

2.3.1 Srovnání modelů

Práce	Model	Benchmark	Pokrytí testy	Úspěšnost
An Empirical Evaluation of Using Large Language Models for Automated Unit Test Generation	<i>gpt-3.5-turbo</i> <i>code-cushman-002</i> <i>StarCoder</i>	Sada NPM balíčků	70.2%	48%
			68.2%	47.1%
			54%	31.5%
Exploring the Effectiveness of Large Language Models in Generating Unit Tests	<i>gpt-3.5-turbo</i>	HumanEval	69.1%	52.3%
		SF110	0.1%	6.9%
	<i>CodeGen</i>	HumanEval	58.2%	23.9%
		SF110	0.5%	30.2%
	<i>Codex (4k)</i>	HumanEval	87.7%	76.7%
		SF110	1.8%	41.1%
Java Unit Testing with AI: An AI-Driven Prototype for Unit Test Generation	<i>gpt-3.5-turbo</i>	JUTAI - Zero-shot, temperature: 0	84.7%	71%

Tabulka 1: Přehled a srovnání studií

Model	Otevřenost	Licence	Počet parametrů	Počet programovacích jazyků	Datum vydání
<i>StarCoderBase</i>	Volně dostupný	CodeML OpenRAIL-M 0.1	15.5 miliardy	80+	5/2023
<i>Code Llama</i>	Volně dostupný	Llama 2 Licence	34 miliard	8+	8/2023
<i>gpt-3.5-turbo</i>	Uzavřený	Proprietární	175 miliard?	?	5/2023
<i>gpt-4</i>	Uzavřený	Proprietární	1.76 bilionu	?	3/2023

Tabulka 2: Přehled a srovnání modelů generujících kód

Reference

- [1] P. Parízek, “Symbolic execution.” Online. Lecture notes for Program Analysis and Verification course.
- [2] Microsoft, “Dynamic symbolic execution - visual studio (windows),” March 2023. Accessed: 2023-10-10.
- [3] Microsoft, “Test generation - visual studio (windows).” <https://learn.microsoft.com/en-us/visualstudio/test/intellitest-manual/test-generation?view=vs-2022>, 3 2023. Accessed: 2023-10-10.
- [4] C. Pacheco, S. K. Lahiri, M. D. Ernst, and T. Ball, “Feedback-directed random test generation,” in *ICSE '07*, (Washington, DC, USA), IEEE Computer Society, 2007.
- [5] M. Schafer, S. Nadi, A. Eghbali, and F. Tip, “An empirical evaluation of using large language models for automated unit test generation,” *arXiv preprint arXiv:2302.06527*, 2023.
- [6] R. Li, L. B. Allal, Y. Zi, N. Muennighoff, D. Kocetkov, *et al.*, “Starcoder: may the source be with you!,” *arXiv preprint arXiv:2305.06161*, 2023.
- [7] M. L. Siddiq, J. C. S. Santos, R. H. Tanvir, N. Ulfat, F. A. Rifat, and V. C. Lopes, “Exploring the effectiveness of large language models in generating unit tests,” *arXiv preprint arXiv:2305.00418*, 2023.
- [8] “Test smells.” <https://testsmells.org/pages/testsmells.html>, 2021. Čteno: 23.10.2023.
- [9] B. Project, “Codeml openrail-m 0.1 license,” 2023. Čteno: 23.10.2023.